YOLO系列

- 深度学习经典检测方法
  - two-stage（两阶段）： Faster-rcnn Mask-Rcnn系列
  - one-stage（单阶段）： YOLO系列

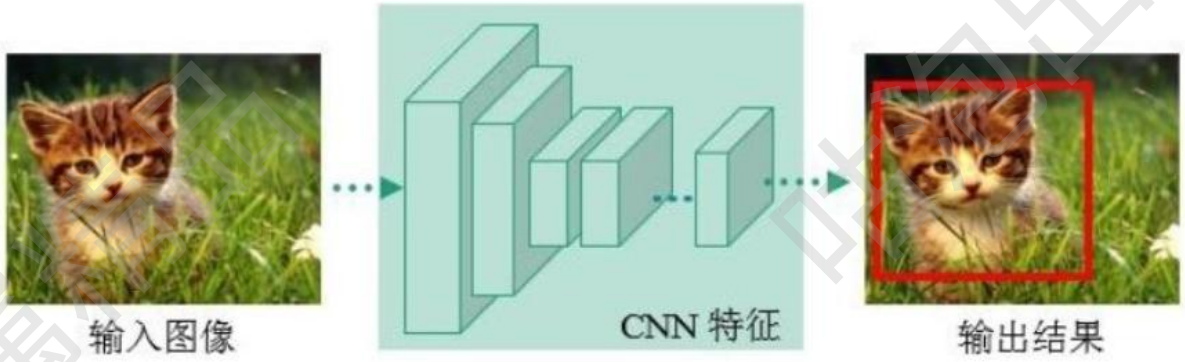

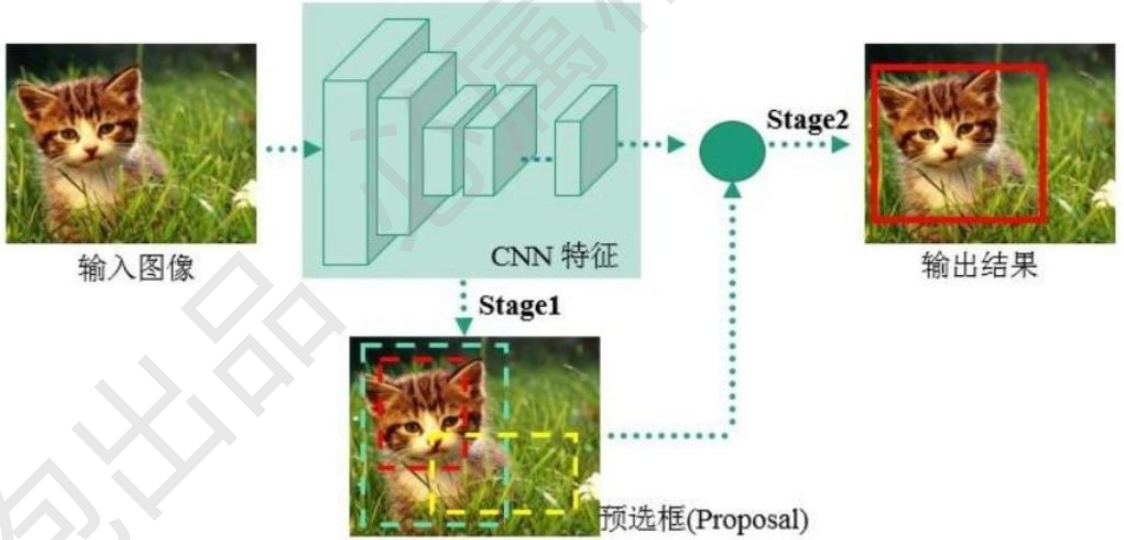

YOLO系列

- one-stage：
  - 最核心的优势：速度非常快，适合做实时检测任务！
  - 但是缺点也是有的，效果通常情况下不会太好！

Model	Train	Test	mAP	FLOPS	FPS	Cfg	Weights
SSD300	COCO trainval	test-dev	41.2	-	46		link
SSD500	COCO trainval	test-dev	46.5	-	19		link
YOLOv2 608x608	COCO trainval	test-dev	48.1	62.94 Bn	40	cfg	weights
Tiny YOLO	COCO trainval	-	-	7.07 Bn	200	cfg	weights

YOLO系列

- two-stage：
  - 速度通常较慢（5FPS），但是效果通常还是不错的!
  - 非常实用的通用框架MaskRcnn，建议熟悉下!

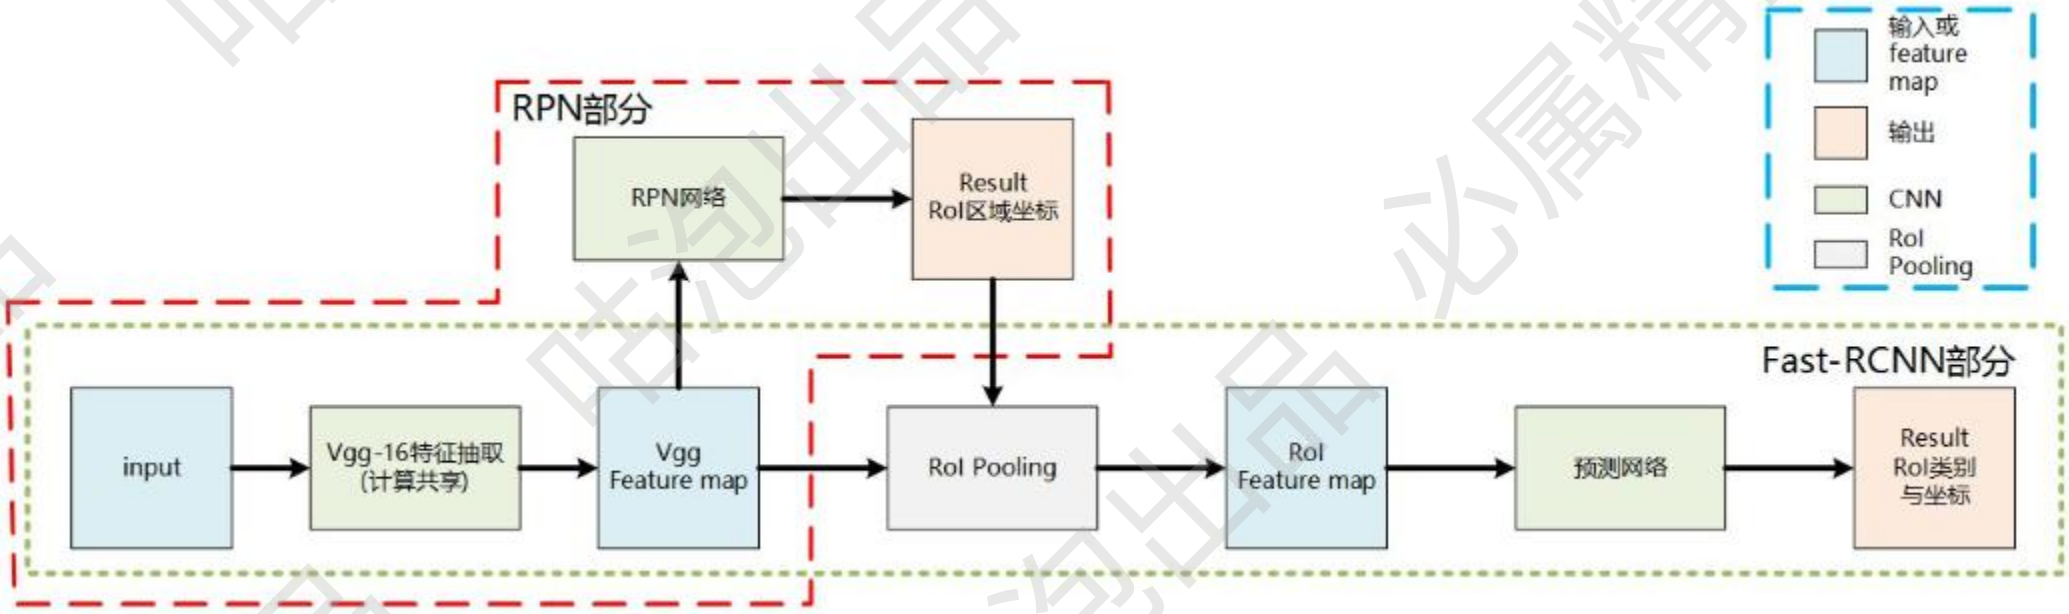

YOLO系列

- 指标分析

  - map指标：综合衡量检测效果；单看精度和recall不行吗？

  - IOU：

$$IoU = \frac{\text{Area of Overlap}}{\text{Area of Union}}$$

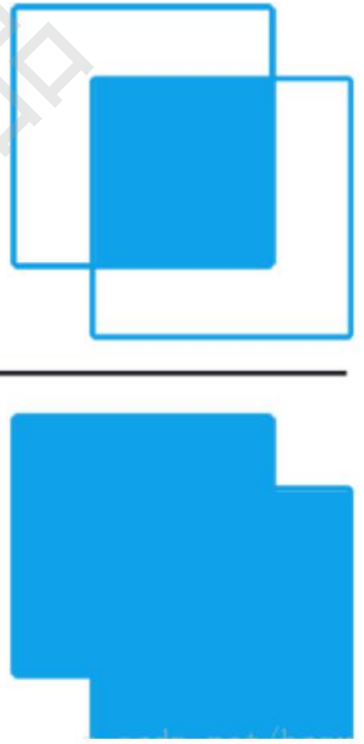

YOLO系列

- 指标分析

- 这几个哥们咱得认识：

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

已知条件：班级总人数100人，其中男生80人，女生20人。
目标：找出所有的女生。
结果：从班级中选择了50人，其中20人是女生，还错误的把30名男生挑选出来了。

	相关(**Relevant**),正类	无关(**NonRelevant**),负类
被检索到 (**Retrieved**)	true positives(TP 正类判定为正类,例子中就是正确的判定"这位是女生")	false positives(FP 负类判定为正类,"存伪",例子中就是分明是男生却判断为女生,当下伪娘横行,这个错常有人犯)
未被检索到 (**Not Retrieved**)	false negatives(FN 正类判定为负类,"去真",例子中就是,分明是女生,这哥们却判断为男生--梁山伯同学犯的错就是这个)	true negatives(TN 负类判定为负类,也就是一个男生被判断为男生,像我这样的纯爷们一准儿就会在此处)

TP = 20; FP = 30; FN = 0; TN = 50;

YOLO系列

- 指标分析

  - 检测任务中的精度和召回率分别代表什么？

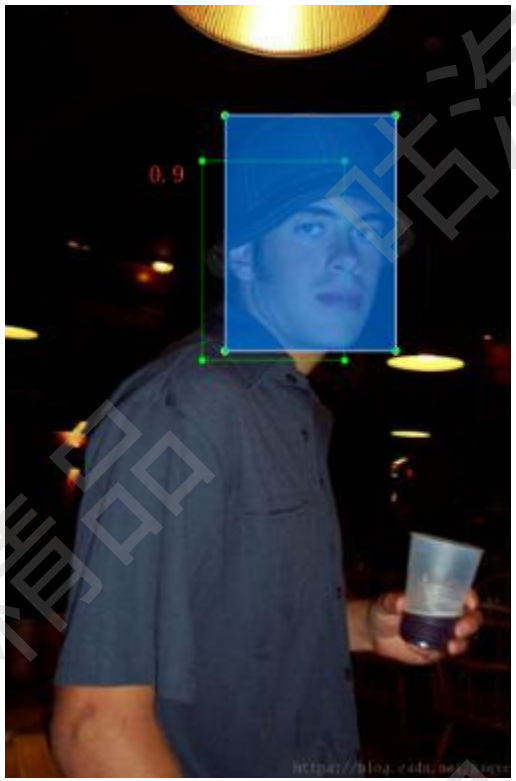

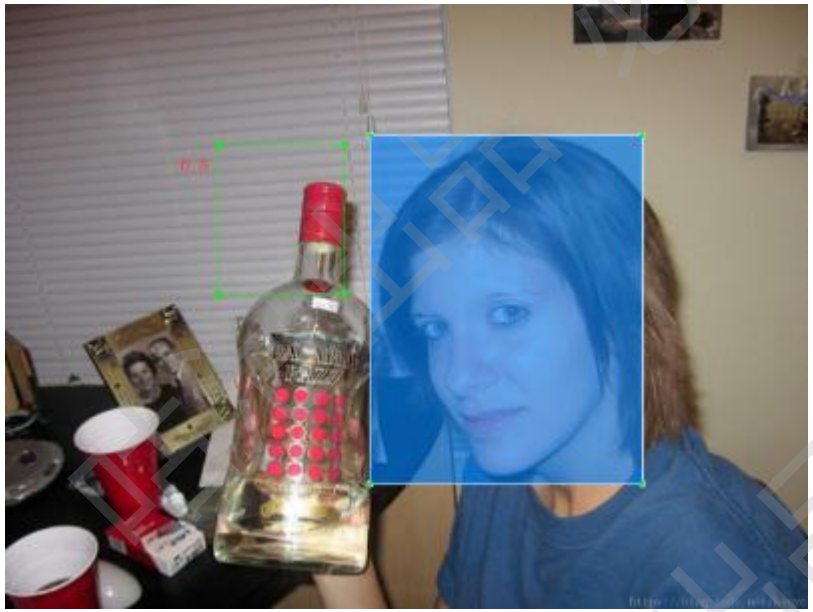

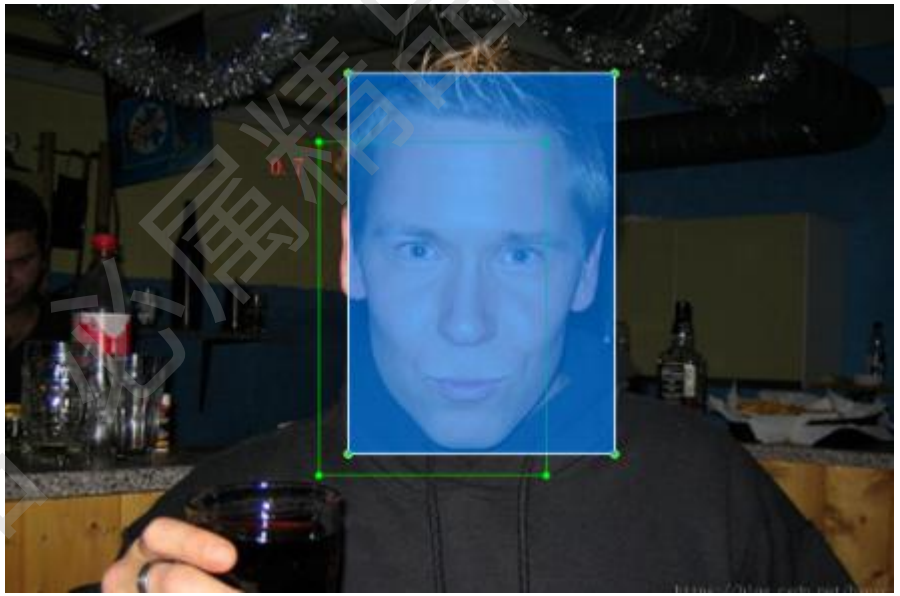

YOLO系列

- 指标分析

  - 基于置信度阈值来计算，例如分别计算0.9；0.8；0.7

  - 0.9时：TP+FP = 1，TP = 1 ；FN = 2；Precision=1/1；Recall=1/3；

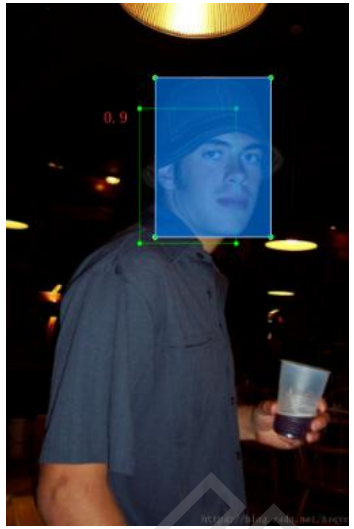

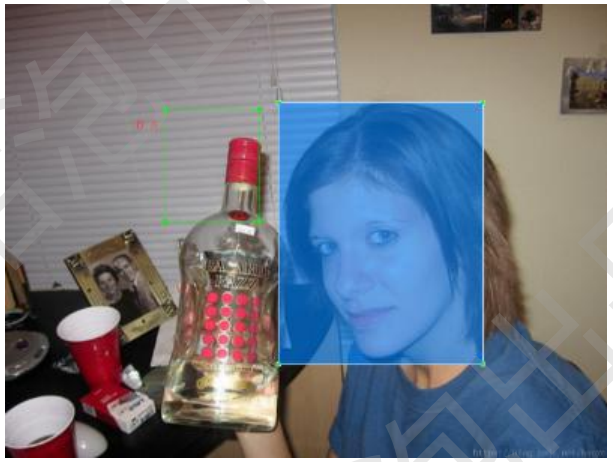

YOLO系列

- 指标分析

如何计算AP呢？需要把所有阈值都考虑进来；MAP就是所有类别的平均

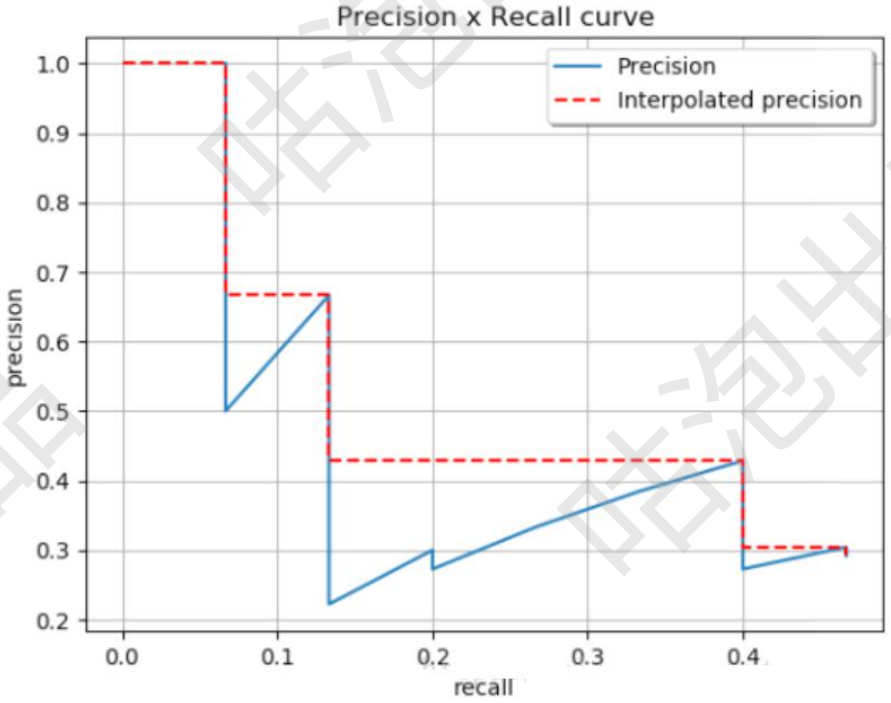

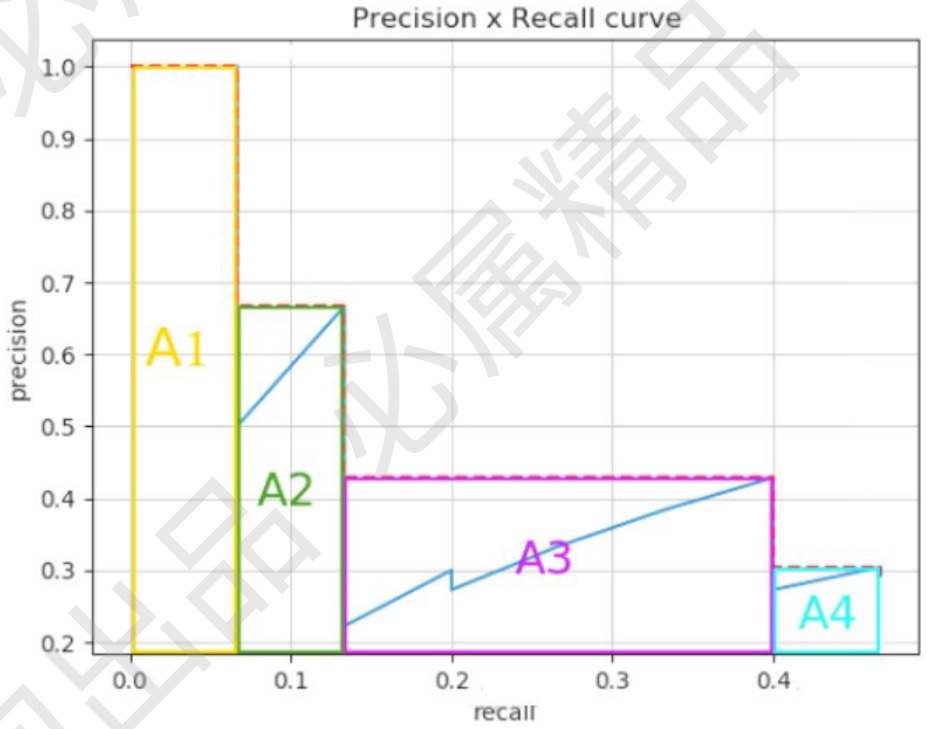

YOLO系列

- YOLO-V1
  - 经典的one-stage方法
  - You Only Look Once，名字就已经说明了一切！
  - 把检测问题转化成回归问题，一个CNN就搞定了！
  - 可以对视频进行实时检测，应用领域非常广！

YOLO系列

- YOLO-V1

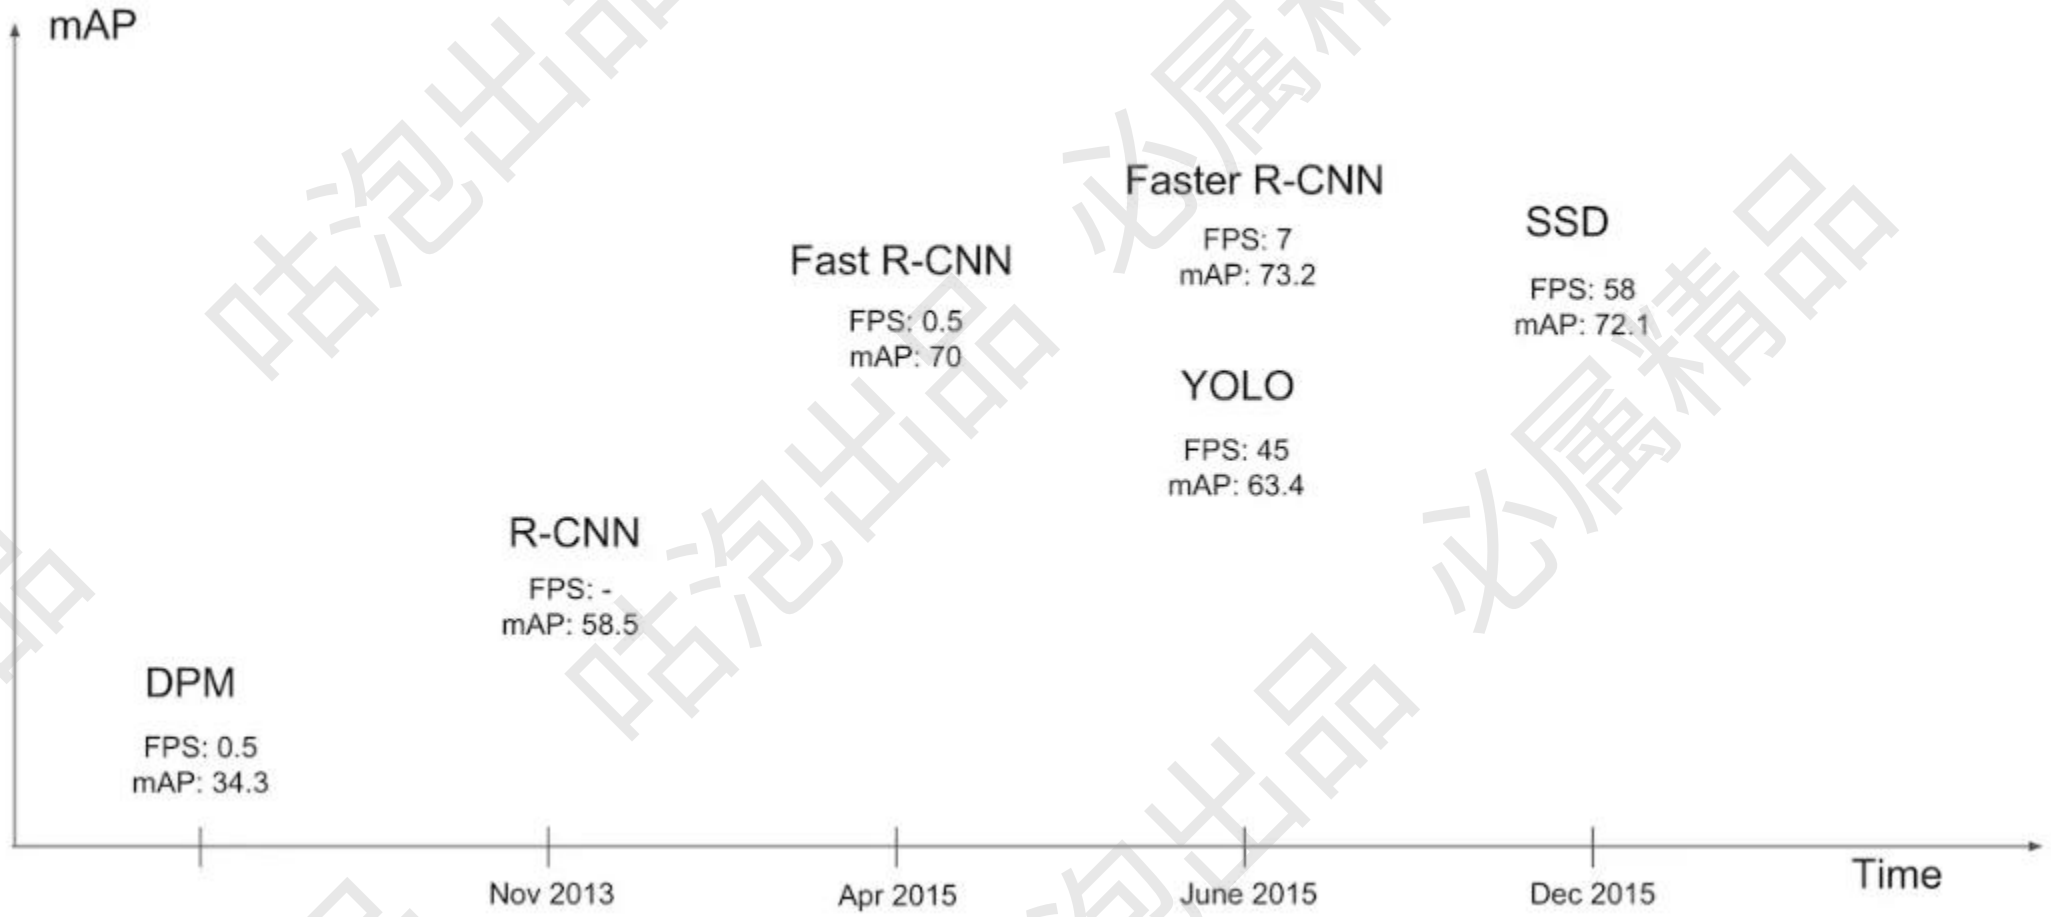

YOLO系列

- 核心思想：

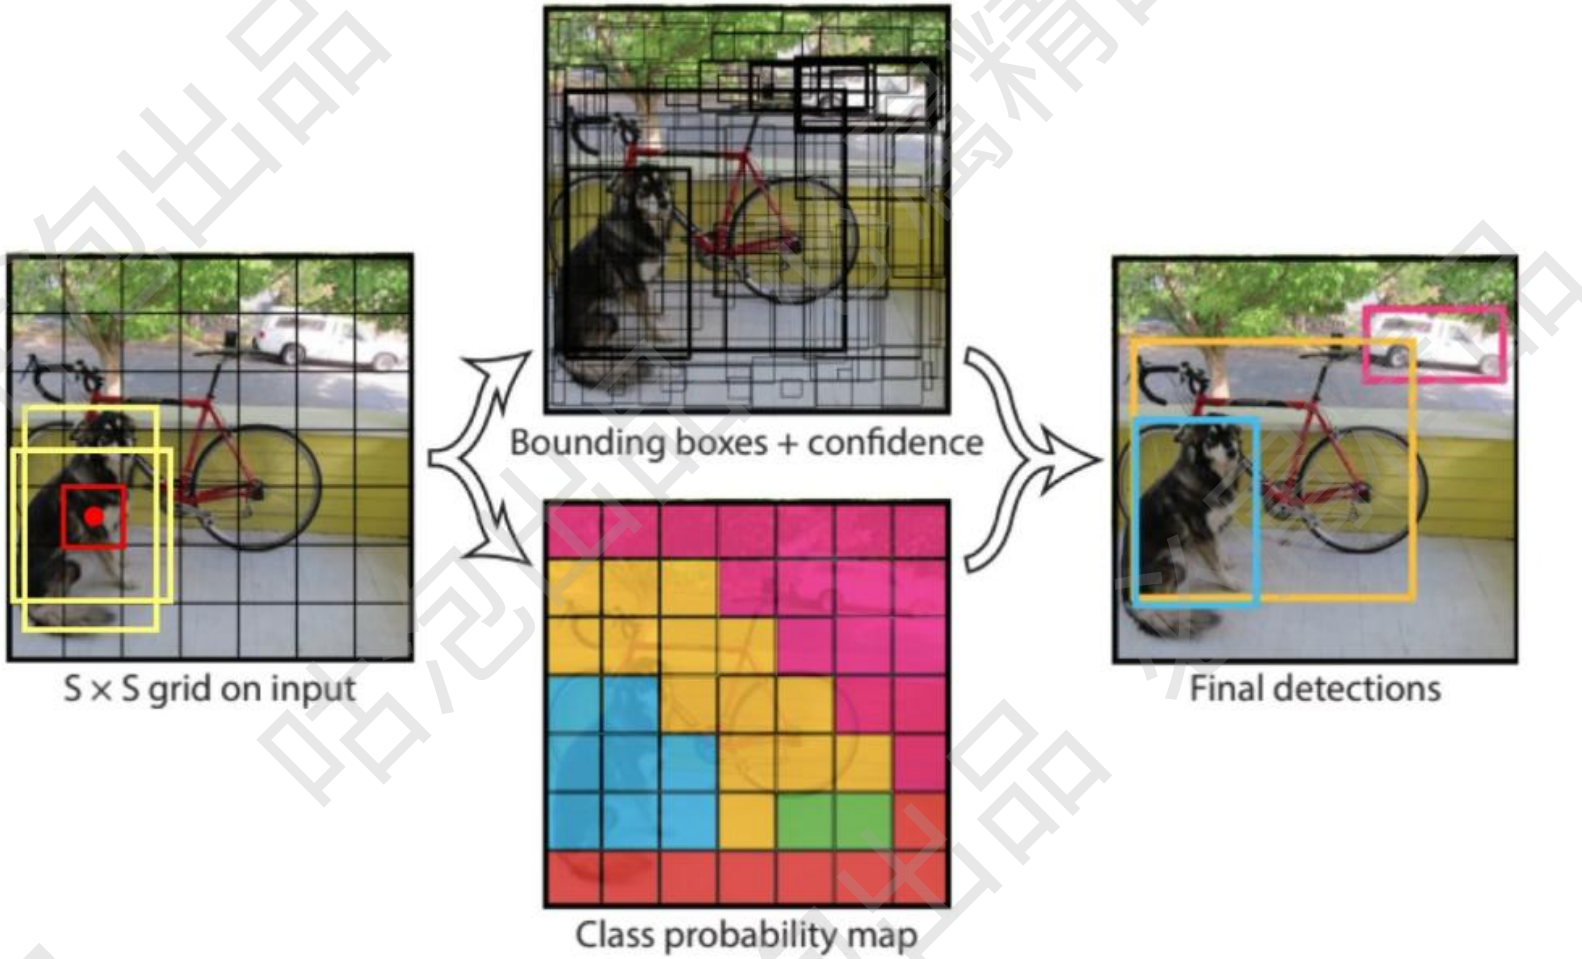
Bounding boxes + confidence
S × S grid on input
Final detections
Class probability map

YOLO系列

- 网络架构

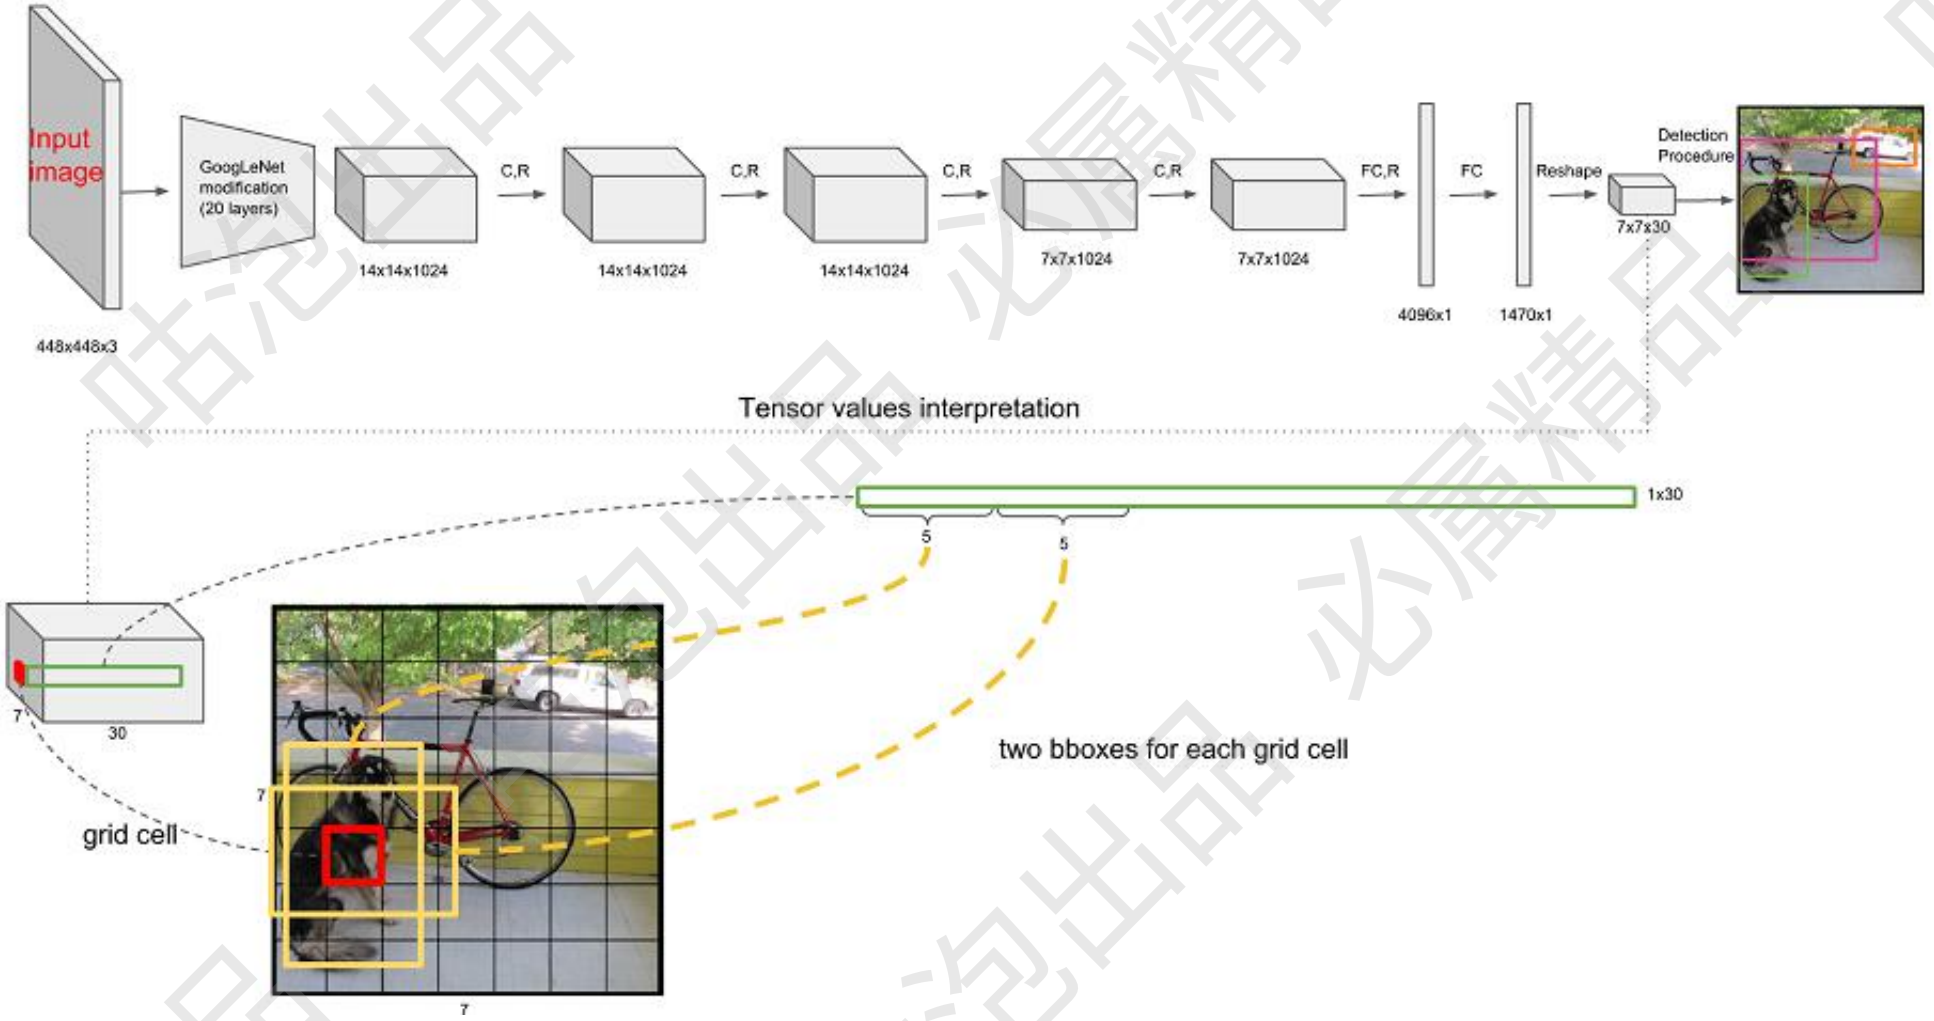
Input image
448x448x3
GoogLeNet modification (20 layers)
14x14x1024
C,R
14x14x1024
C,R
14x14x1024
C,R
7x7x1024
C,R
7x7x1024
FC,R
4096x1
FC
1470x1
Reshape
7x7x30
Detection Procedure
Tensor values interpretation
1x30
5
5
7
7
30
grid cell
7
7
two bboxes for each grid cell

YOLO系列

- 每个数字的含义：
  - 10 =(X,Y,H,W,C)*B（2个）
  - 当前数据集中有20个类别
  - 7*7表示最终网格的大小
  - （S*S）*（B*5+C）

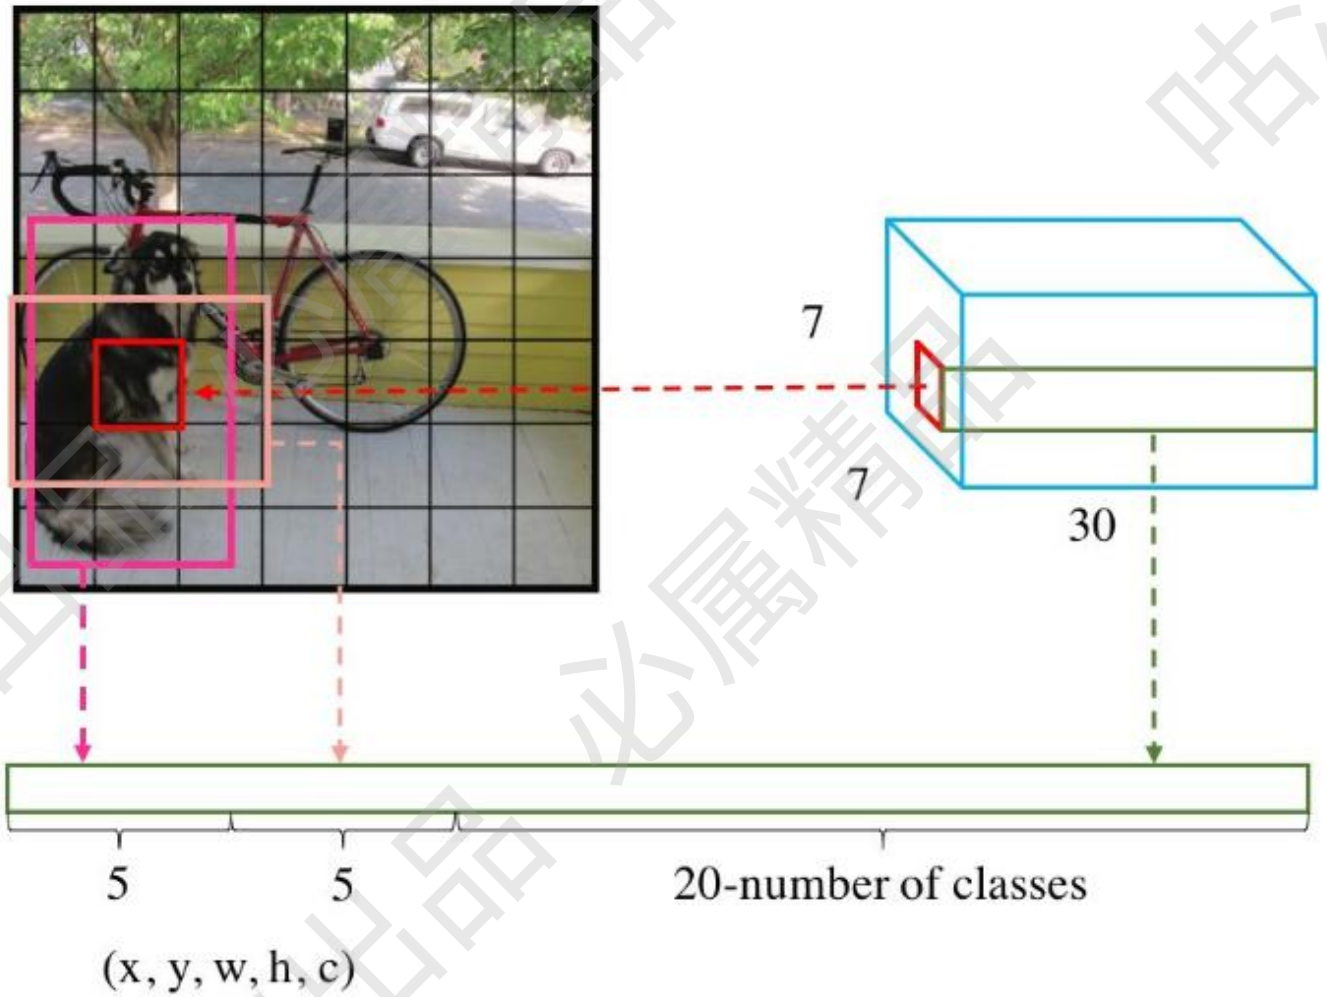

YOLO系列

- 损失函数：

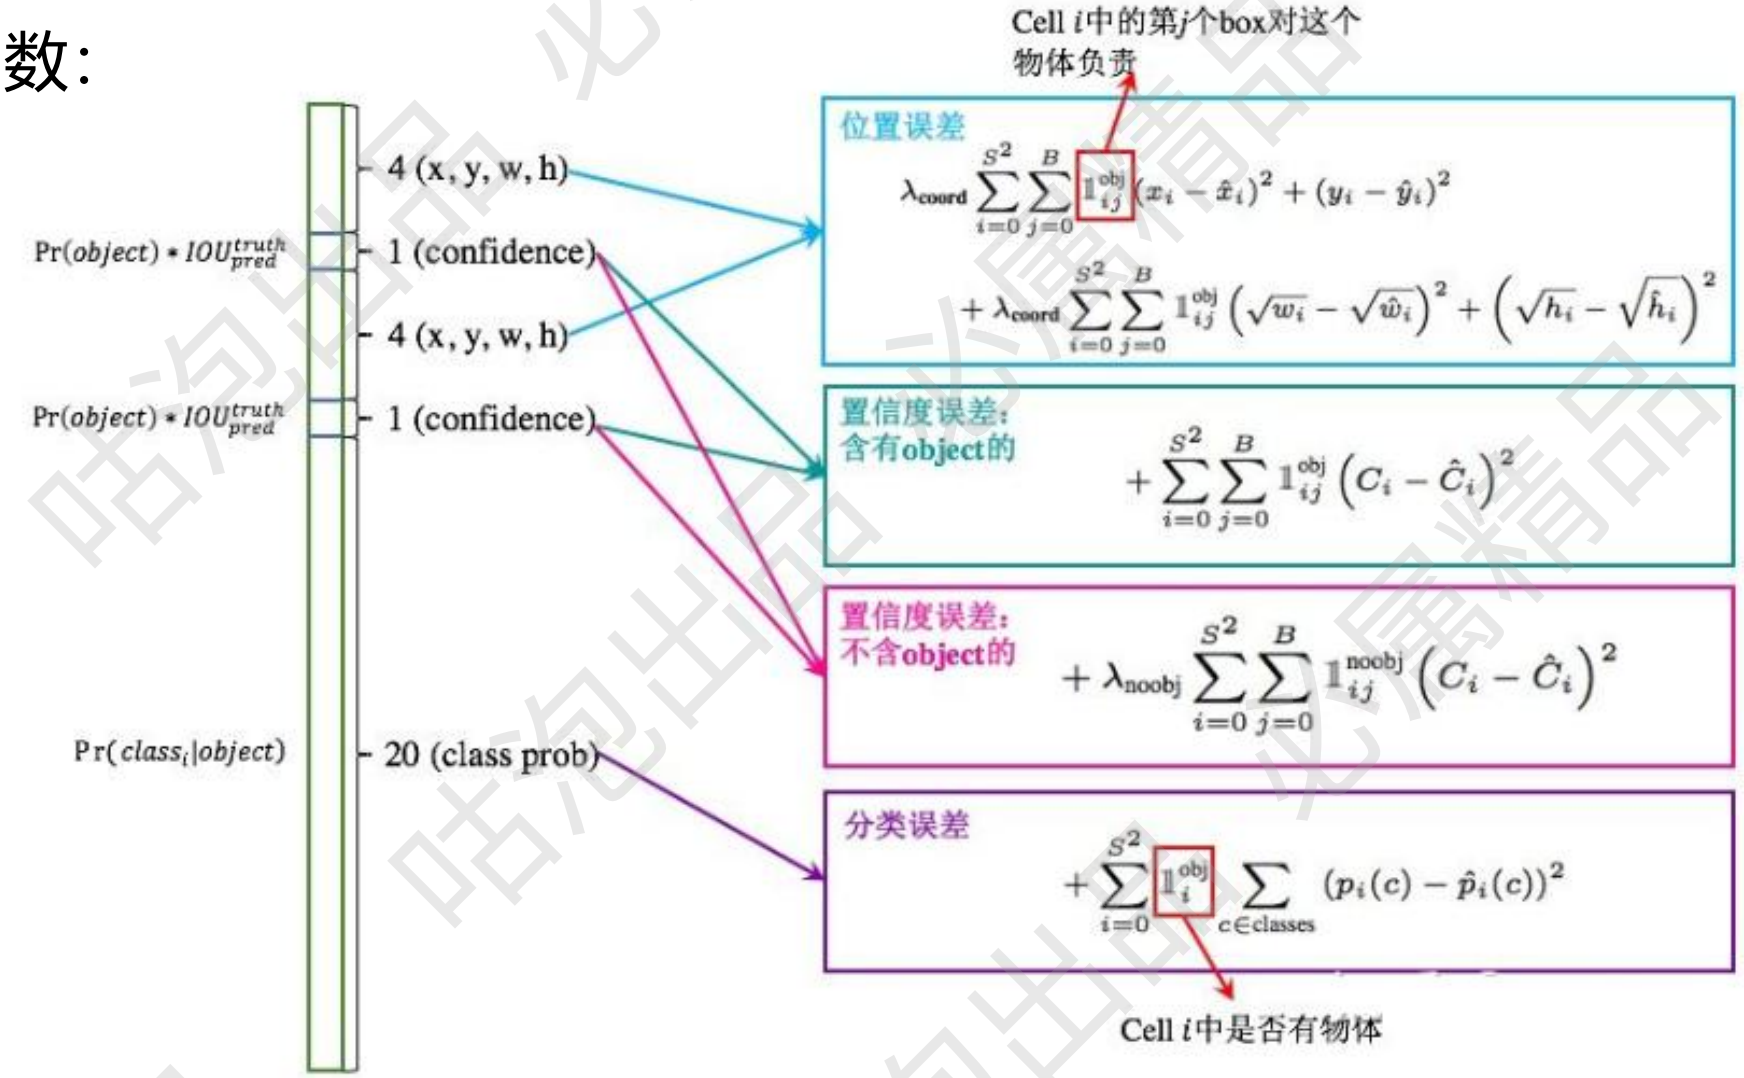
Cell i中的第j个box对这个物体负责
4 (x, y, w, h)
$\Pr(object) * IOU^{truth}_{pred}$
1 (confidence)
4 (x, y, w, h)
$\Pr(object) * IOU^{truth}_{pred}$
1 (confidence)
$\Pr(class_i|object)$
20 (class prob)
位置误差
$\lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{obj} (x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2$
$+ \lambda_{coord} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{obj} \left(\sqrt{w_i} - \sqrt{\hat{w}_i}\right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i}\right)^2$
置信度误差：含有object的
$+ \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{obj} \left(C_i - \hat{C}_i\right)^2$
置信度误差：不含object的
$+ \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^{B} \mathbb{1}_{ij}^{noobj} \left(C_i - \hat{C}_i\right)^2$
分类误差
$+ \sum_{i=0}^{S^2} \mathbb{1}_{i}^{obj} \sum_{c \in classes} (p_i(c) - \hat{p}_i(c))^2$
Cell i中是否有物体

YOLO系列

- NMS(非极大值抑制)

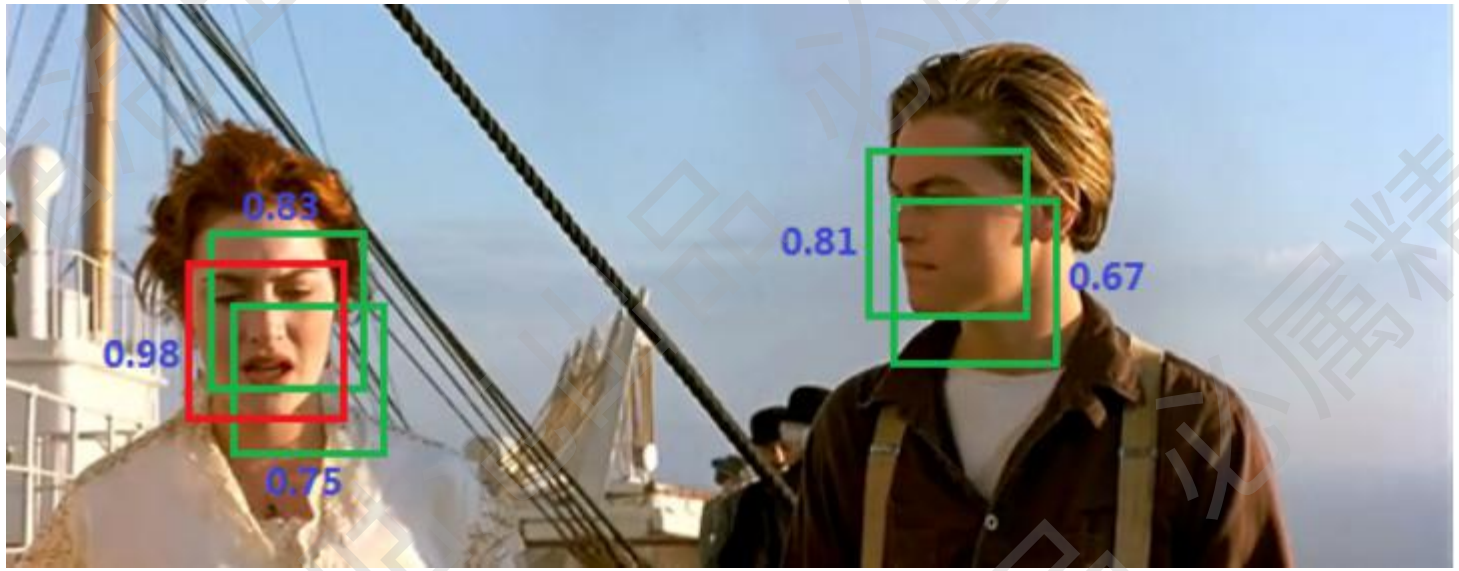

YOLO系列

- YOLO-V1
  - 优点：快速，简单！
  - 问题1：每个Cell只预测一个类别，如果重叠无法解决
  - 问题2：小物体检测效果一般，长宽比可选的但单一

YOLO系列

- YOLO-V2

  - 更快！更强！

	YOLO								YOLOv2
batch norm?		✓	✓	✓	✓	✓	✓	✓	✓
hi-res classifier?			✓	✓	✓	✓	✓	✓	✓
convolutional?				✓	✓	✓	✓	✓	✓
anchor boxes?				✓	✓				
new network?					✓	✓	✓	✓	✓
dimension priors?						✓	✓	✓	✓
location prediction?						✓	✓	✓	✓
passthrough?							✓	✓	✓
multi-scale?								✓	✓
hi-res detector?									✓
VOC2007 mAP	63.4	65.8	69.5	69.2	69.6	74.4	75.4	76.8	**78.6**

YOLO系列

- YOLO-V2-Batch Normalization
  - V2版本舍弃Dropout，卷积后全部加入Batch Normalization
  - 网络的每一层的输入都做了归一化，收敛相对更容易
  - 经过Batch Normalization处理后的网络会提升2%的mAP
  - 从现在的角度来看，Batch Normalization已经成网络必备处理

YOLO系列

- YOLO-V2-更大的分辨率
  - V1训练时用的是224*224，测试时使用448*448
  - 可能导致模型水土不服，V2训练时额外又进行了10次448*448 的微调
  - 使用高分辨率分类器后，YOLOv2的mAP提升了约4%

YOLO系列

- YOLO-V2-网络结构
  - DarkNet，实际输入为416*416
  - 没有FC层，5次降采样，（13*13）
  - 1*1卷积节省了很多参数

Type	Filters	Size/Stride	Output
Convolutional	32	3 × 3	224 × 224
Maxpool		2 × 2/2	112 × 112
Convolutional	64	3 × 3	112 × 112
Maxpool		2 × 2/2	56 × 56
Convolutional	128	3 × 3	56 × 56
Convolutional	64	1 × 1	56 × 56
Convolutional	128	3 × 3	56 × 56
Maxpool		2 × 2/2	28 × 28
Convolutional	256	3 × 3	28 × 28
Convolutional	128	1 × 1	28 × 28
Convolutional	256	3 × 3	28 × 28
Maxpool		2 × 2/2	14 × 14
Convolutional	512	3 × 3	14 × 14
Convolutional	256	1 × 1	14 × 14
Convolutional	512	3 × 3	14 × 14
Convolutional	256	1 × 1	14 × 14
Convolutional	512	3 × 3	14 × 14
Maxpool		2 × 2/2	7 × 7
Convolutional	1024	3 × 3	7 × 7
Convolutional	512	1 × 1	7 × 7
Convolutional	1024	3 × 3	7 × 7
Convolutional	512	1 × 1	7 × 7
Convolutional	1024	3 × 3	7 × 7
Convolutional	1000	1 × 1	7 × 7
Avgpool		Global	1000
Softmax			

YOLO系列

- YOLO-V2-聚类提取先验框

  - faster-rcnn系列选择的先验比例都是常规的，但是不一定完全适合数据集

  - K-means聚类中的距离： $d(box, centroids) = 1 - IOU(box, centroids)$

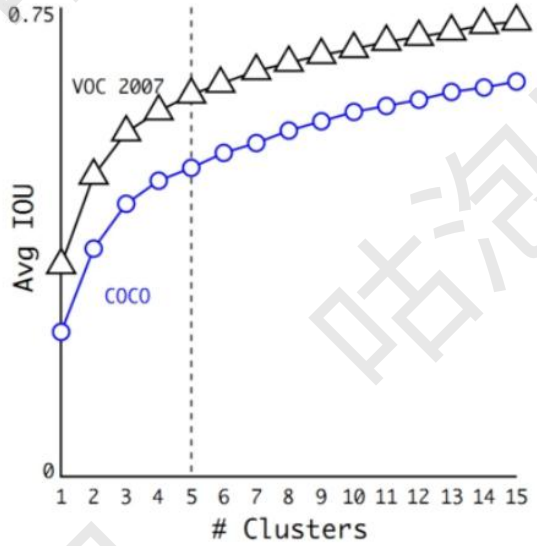

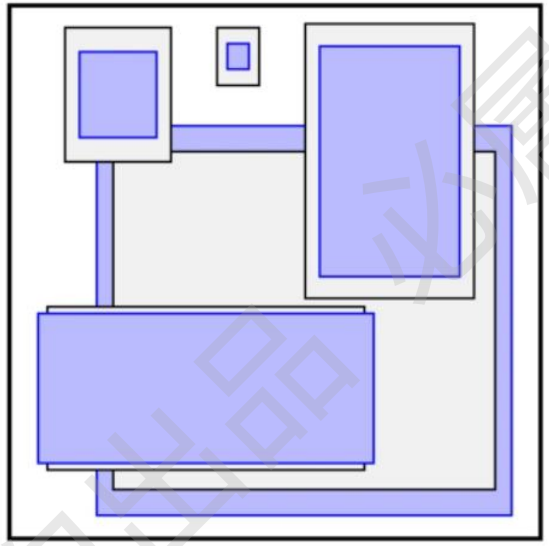

YOLO系列

- YOLO-V2-Anchor Box

  - 通过引入anchor boxes，使得预测的box数量更多（13*13*n）

  - 跟faster-rcnn系列不同的是先验框并不是直接按照长宽固定比给定

without anchor	69.5 mAP	81% recall
with anchor	69.2 mAP	88% recall

YOLO系列

- YOLO-V2-Directed Location Prediction
  - bbox：中心为(xp,yp)；宽和高为(wp,hp)，则：
$$x = x_p + w_p * tx$$
$$y = y_p + h_p * ty$$
  - tx=1,则将bbox在x轴向右移动wp；tx=−1则将其向左移动wp
  - 这样会导致收敛问题，模型不稳定，尤其是刚开始进行训练的时候
  - V2中并没有直接使用偏移量，而是选择相对grid cell的偏移量

YOLO系列

- YOLO-V2-Directed Location Prediction

计算公式为：

$$
\begin{aligned}
b_x &= \sigma(t_x) + c_x \\
b_y &= \sigma(t_y) + c_y \\
b_w &= p_w e^{t_w} \\
b_h &= p_h e^{t_h}
\end{aligned}
$$

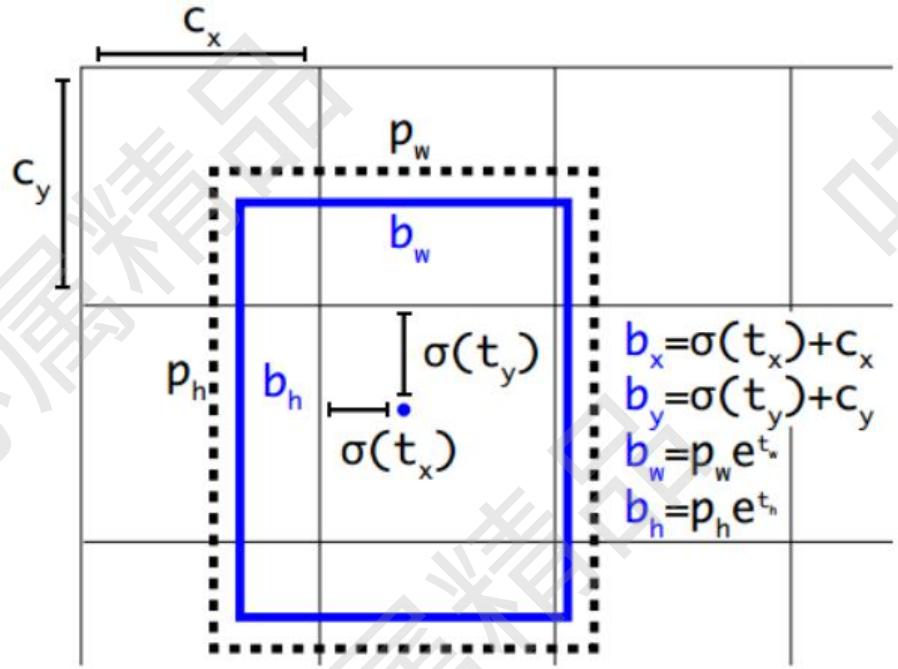

例如预测值(σtx,σty,tw,th)=(0.2,0.1,0.2,0.32)，anchor框为$p_w = 3.19275, p_h = 4.00944$

在特征图位置：

$$
\begin{aligned}
b_x &= 0.2 + 1 = 1.2 \\
b_y &= 0.1 + 1 = 1.1 \\
b_w &= 3.19275 * e^{0.2} = 3.89963 \\
b_h &= 4.00944 * e^{0.32} = 5.52151
\end{aligned}
$$

在原位置：

$$
\begin{aligned}
b_x &= 1.2 * 32 = 38.4 \\
b_y &= 1.1 * 32 = 35.2 \\
b_w &= 3.89963 * 32 = 124.78 \\
b_h &= 5.52151 * 32 = 176.68
\end{aligned}
$$

YOLO系列

感受野

概述来说就是特征图上的点能看到原始图像多大区域

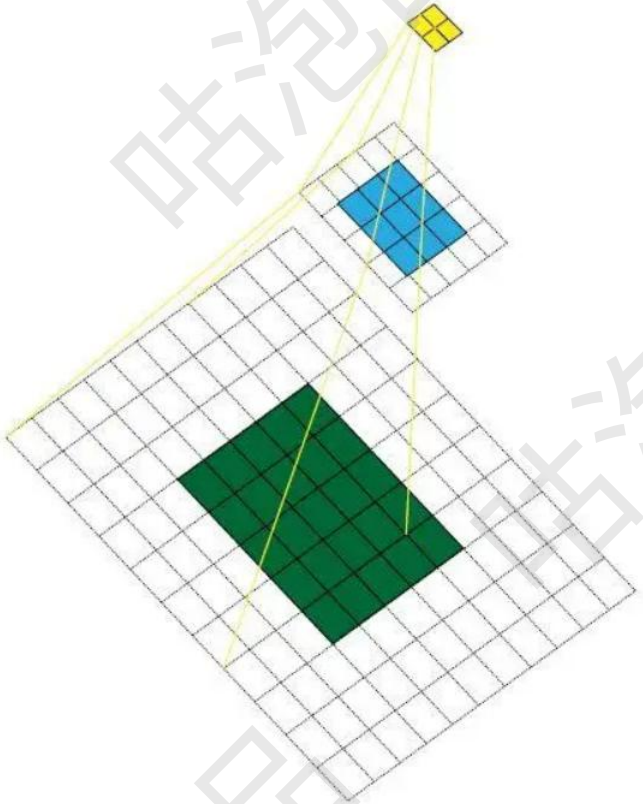

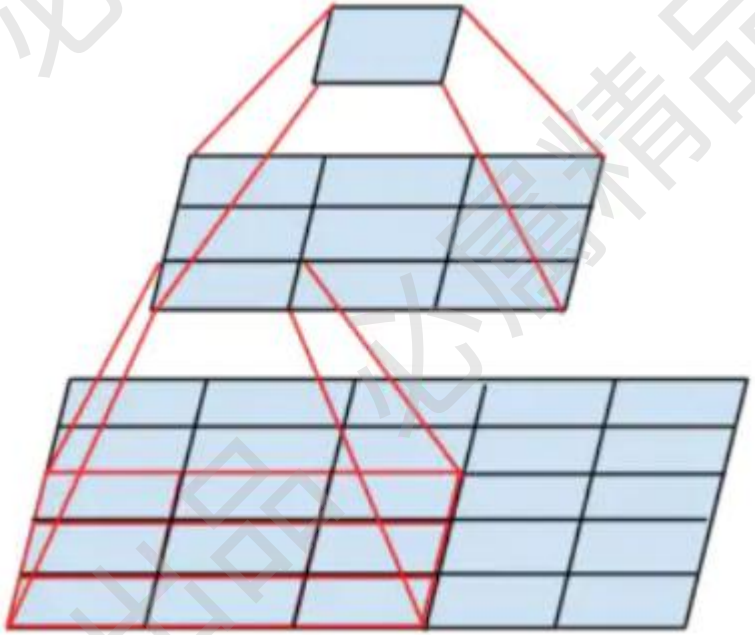

YOLO系列

- 感受野：

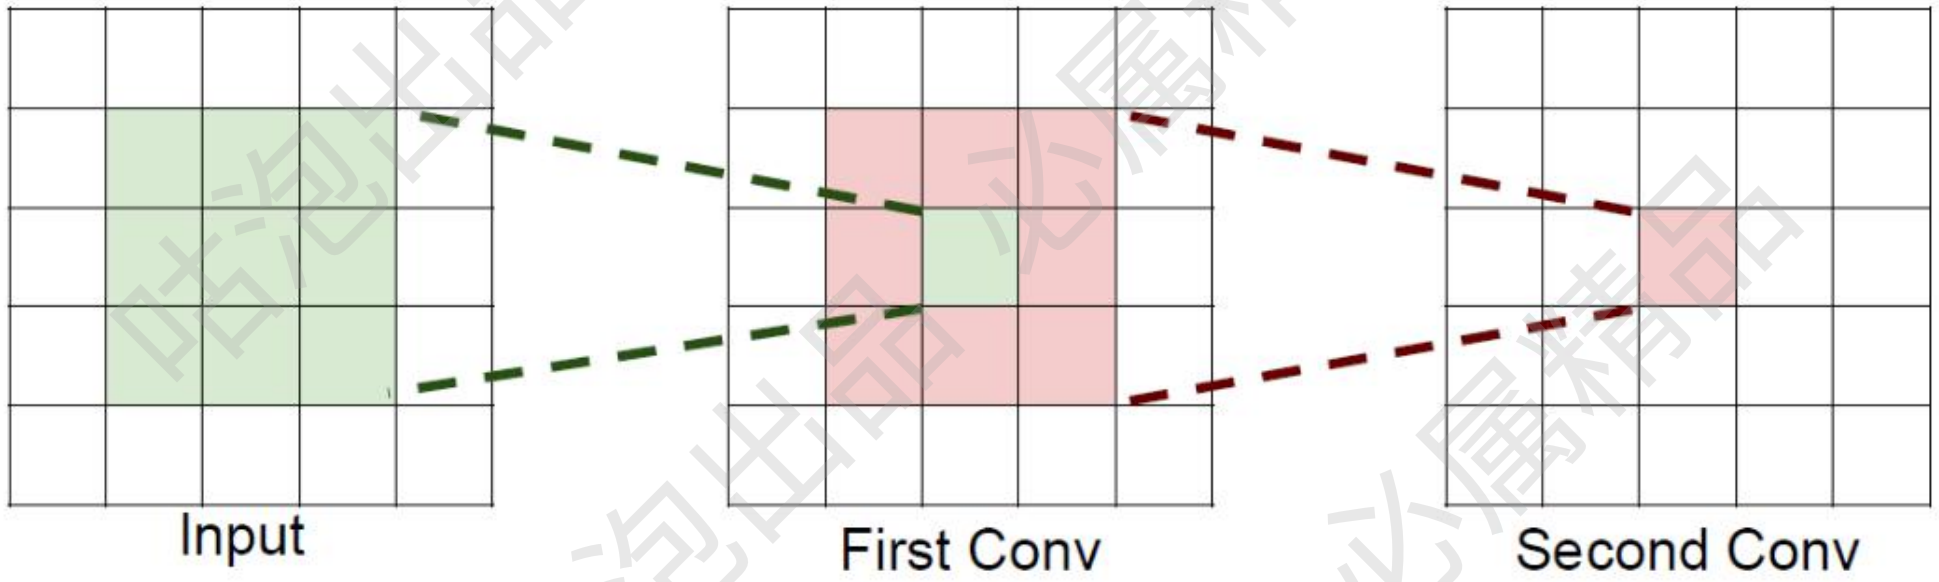

- 如果堆叠3个3*3的卷积层，并且保持滑动窗口步长为1，其感受野就是7*7的了，这跟一个使用7*7卷积核的结果是一样的，那为什么非要堆叠3个小卷积呢?

YOLO系列

感受野

假设输入大小都是h*w*c，并且都使用c个卷积核(得到c个特征图)，可以来计算一下其各自所需参数：

一个7*7卷积核所需参数：

$= C \times (7 \times 7 \times C) = \mathbf{49\ C^2}$

3个3*3卷积核所需参数：

$= 3 \times C \times (3 \times 3 \times C) = \mathbf{27\ C^2}$

很明显，堆叠小的卷积核所需的参数更少一些，并且卷积过程越多，特征提取也会越细致，加入的非线性变换也随着增多，还不会增大权重参数个数，这就是VGG网络的基本出发点，用小的卷积核来完成体特征提取操作。

YOLO系列

- YOLO-V2-Fine-Grained Features

  - 最后一层时感受野太大了，小目标可能丢失了，需融合之前的特征

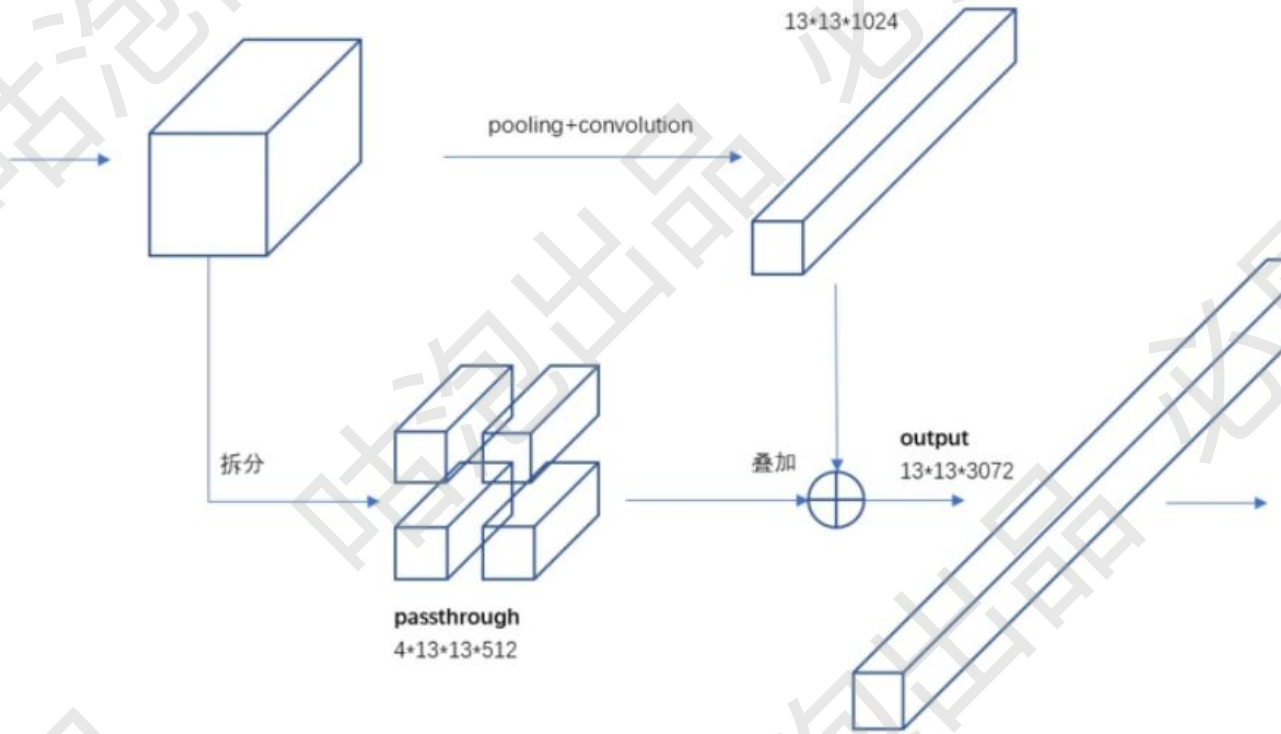

YOLO系列

- YOLO-V2-Multi-Scale

  - 都是卷积操作可没人能限制我了！一定iterations之后改变输入图片大小

    最小的图像尺寸为320 x 320

    最大的图像尺寸为608 x 608

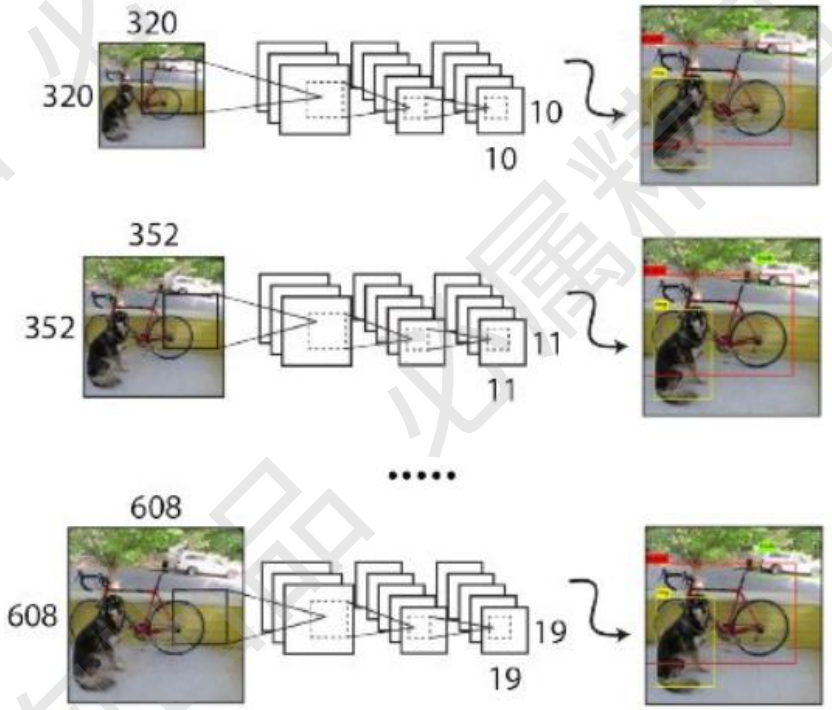

YOLO系列

- YOLO-V3

这张图讲道理真的过分了！！！ 我不是针对谁，在座的各位都是、、、

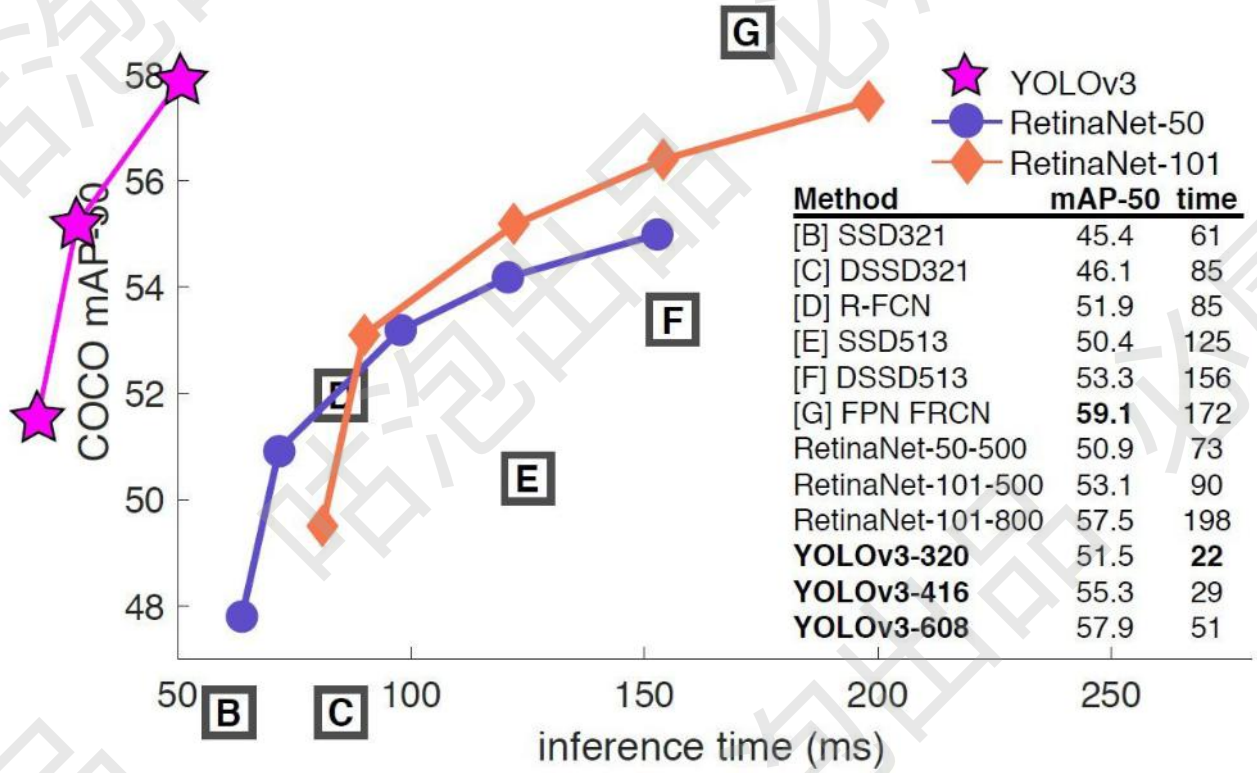

Method	mAP-50	time
[B] SSD321	45.4	61
[C] DSSD321	46.1	85
[D] R-FCN	51.9	85
[E] SSD513	50.4	125
[F] DSSD513	53.3	156
[G] FPN FRCN	**59.1**	172
RetinaNet-50-500	50.9	73
RetinaNet-101-500	53.1	90
RetinaNet-101-800	57.5	198
YOLOv3-320	51.5	**22**
YOLOv3-416	55.3	29
YOLOv3-608	57.9	51

YOLO系列

- YOLO-V3
  - 终于到V3了，最大的改进就是网络结构，使其更适合小目标检测
  - 特征做的更细致，融入多持续特征图信息来预测不同规格物体
  - 先验框更丰富了，3种scale，每种3个规格，一共9种
  - softmax改进，预测多标签任务

YOLO系列

- 多scale

  为了能检测到不同大小的物体，设计了3个scale

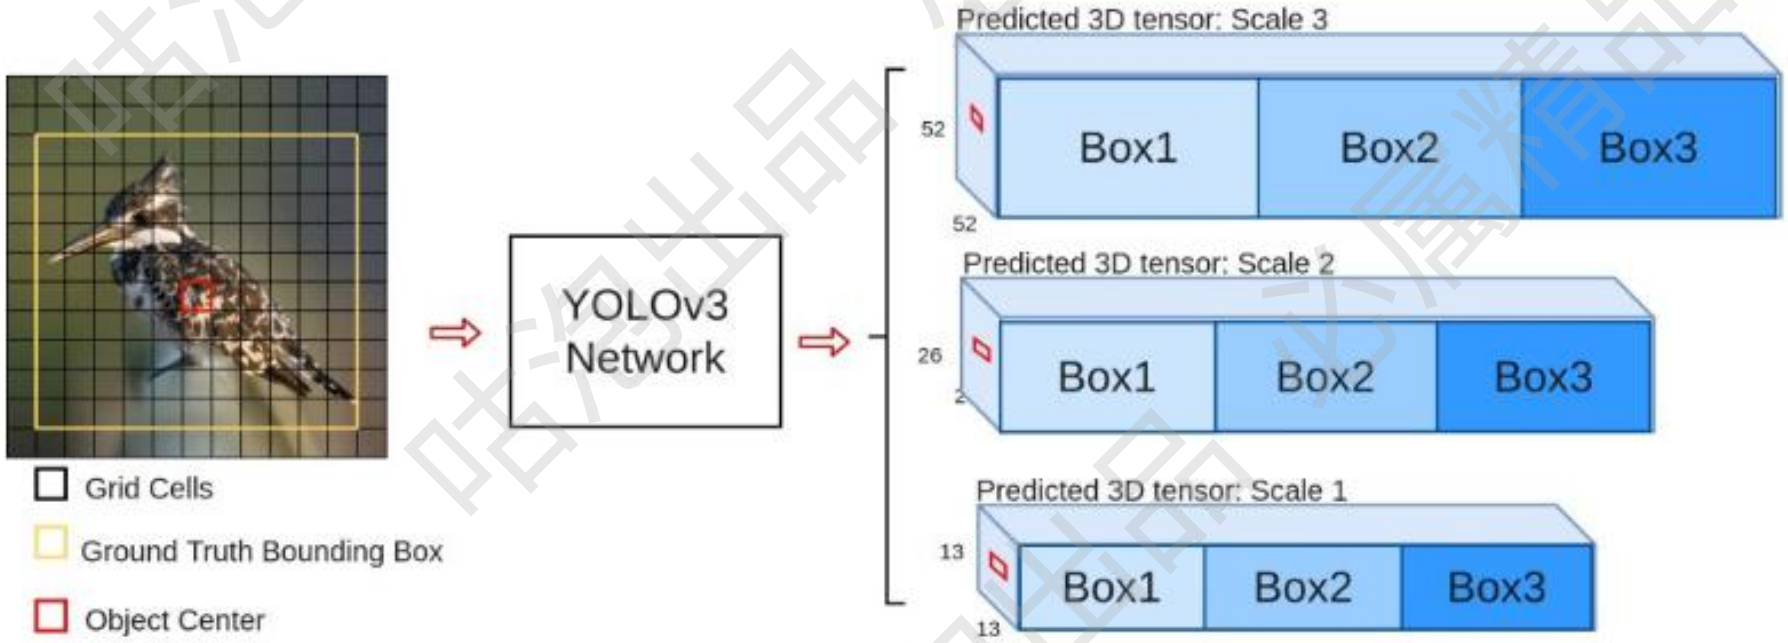

YOLO系列

- scale变换经典方法

  - 左图：图像金字塔；右图：单一的输入；

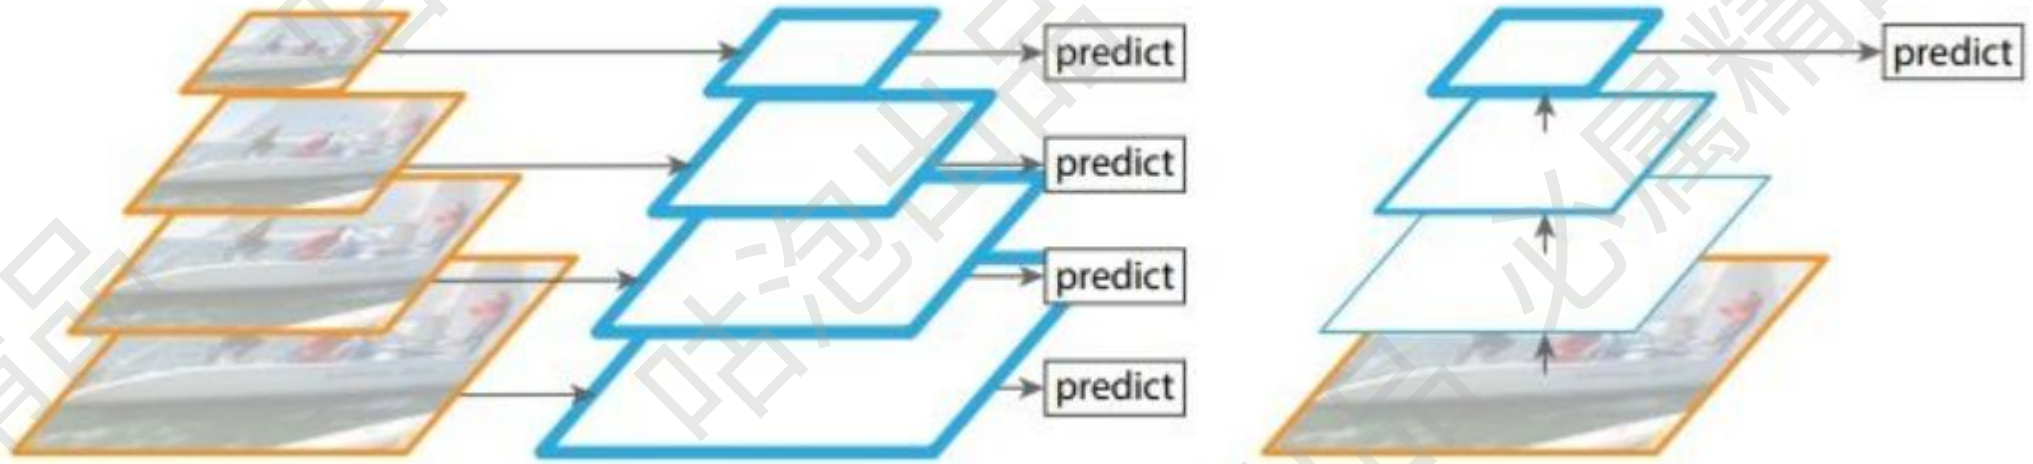

YOLO系列

- scale变换经典方法

  - 左图：对不同的特征图分别利用；右图：不同的特征图融合后进行预测；

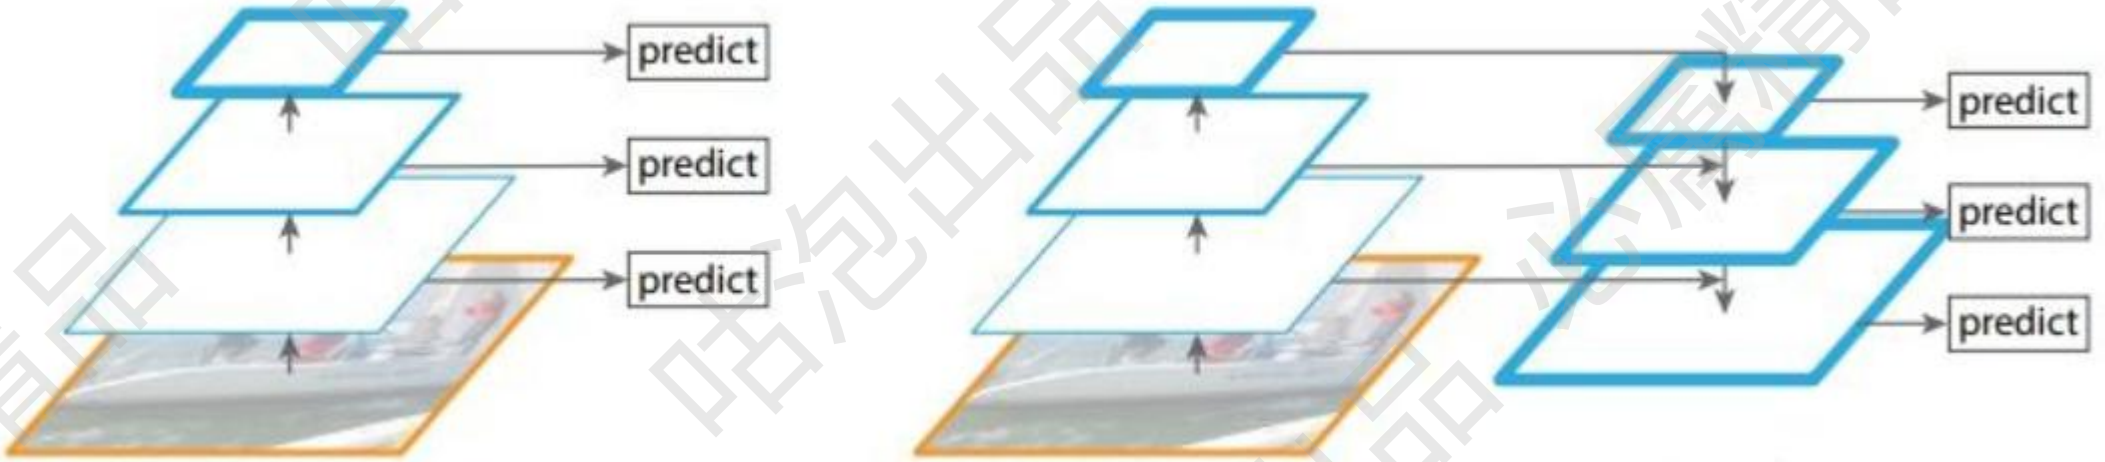

YOLO系列

- 残差连接-为了更好的特征
  - 从今天的角度来看，基本所有网络架构都用上了残差连接的方法
  - V3中也用了resnet的思想，堆叠更多的层来进行特征提取

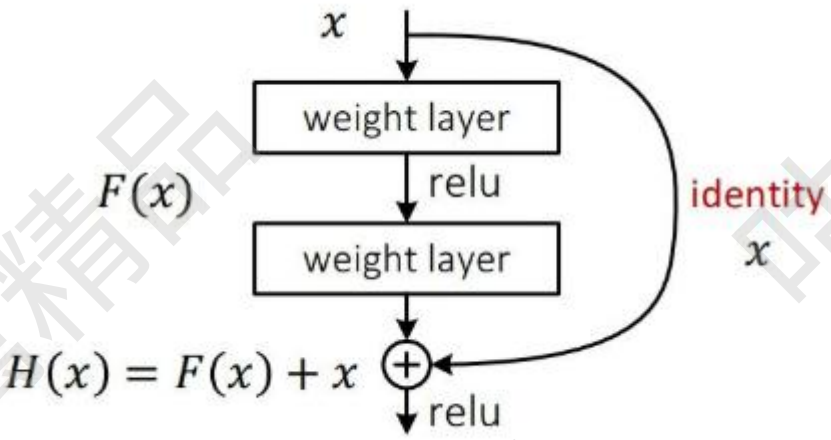

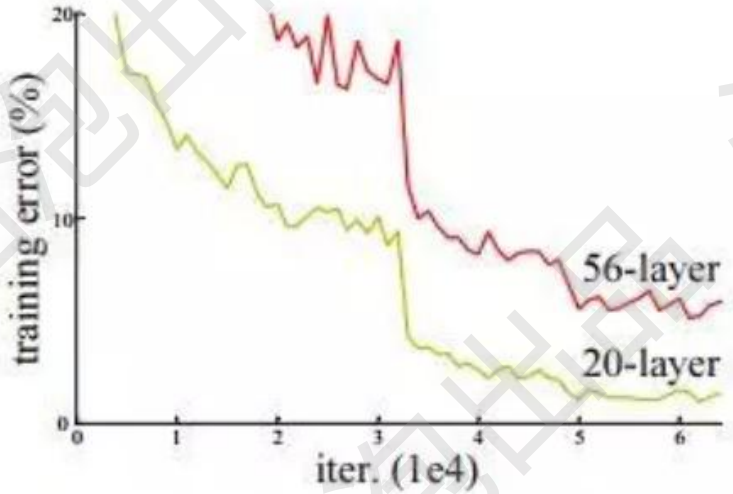

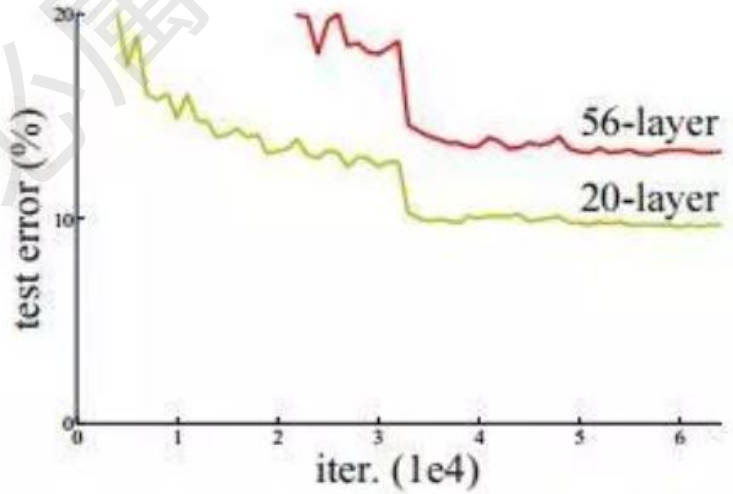

YOLO系列

- 核心网络架构
  - 没有池化和全连接层，全部卷积
  - 下采样通过stride为2实现
  - 3种scale，更多先验框
  - 基本上当下经典做法全融入了

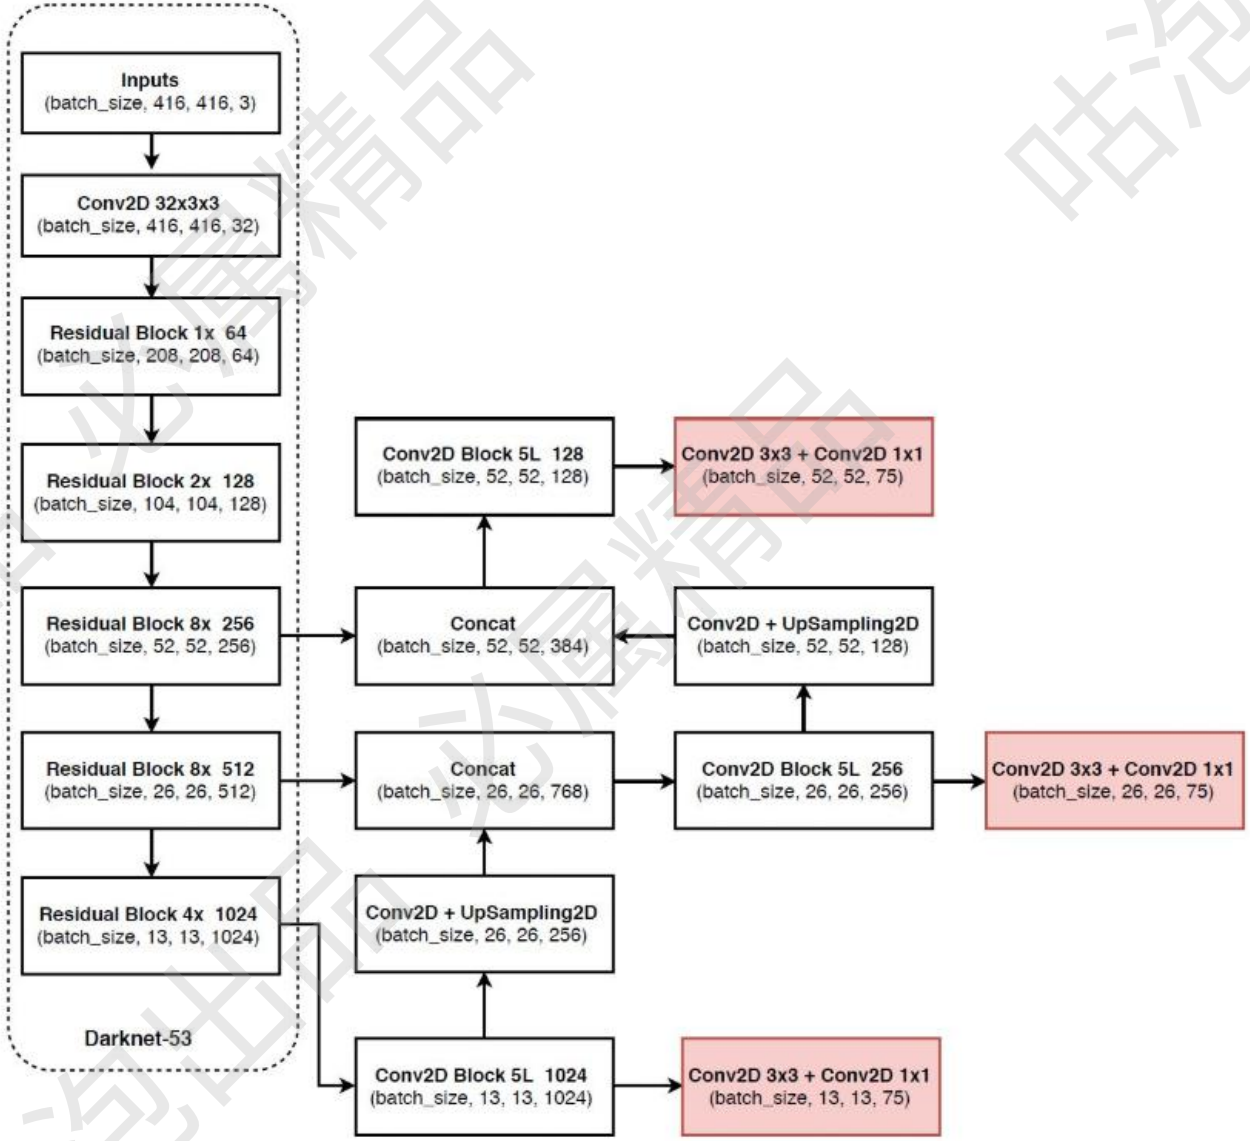

YOLO系列

- 核心网络架构

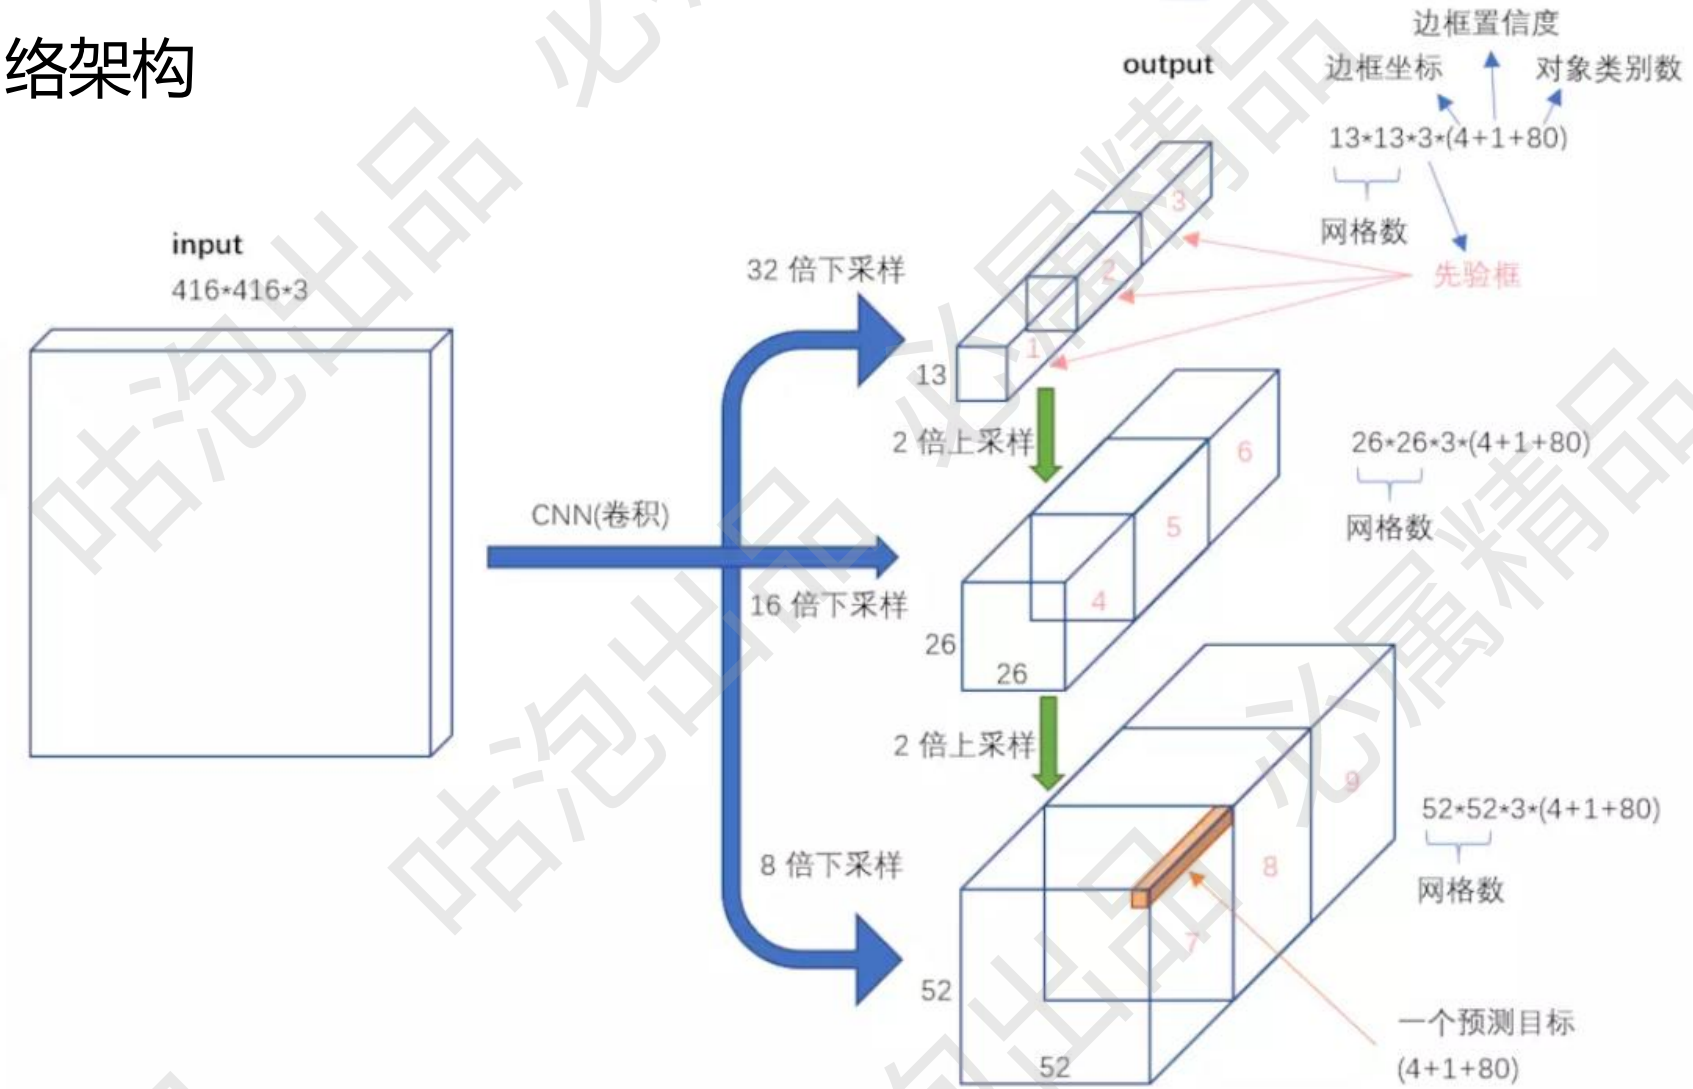

YOLO系列

先验框设计

- YOLO-V2中选了5个，这回更多了，一共有9种
- 13*13特征图上：(116x90)，(156x198)，(373x326)

  26*26特征图上：(30x61)，(62x45)，(59x119)

  52*52特征图上：(10x13)，(16x30)，(33x23)

特征图	13*13			26*26			52*52		
感受野	大			中			小		
先验框	(116x90)	(156x198)	(373x326)	(30x61)	(62x45)	(59x119)	(10x13)	(16x30)	(33x23)

YOLO系列

- 先验框设计

- YOLO-V2中选了5个，这回更多了，一共有9种

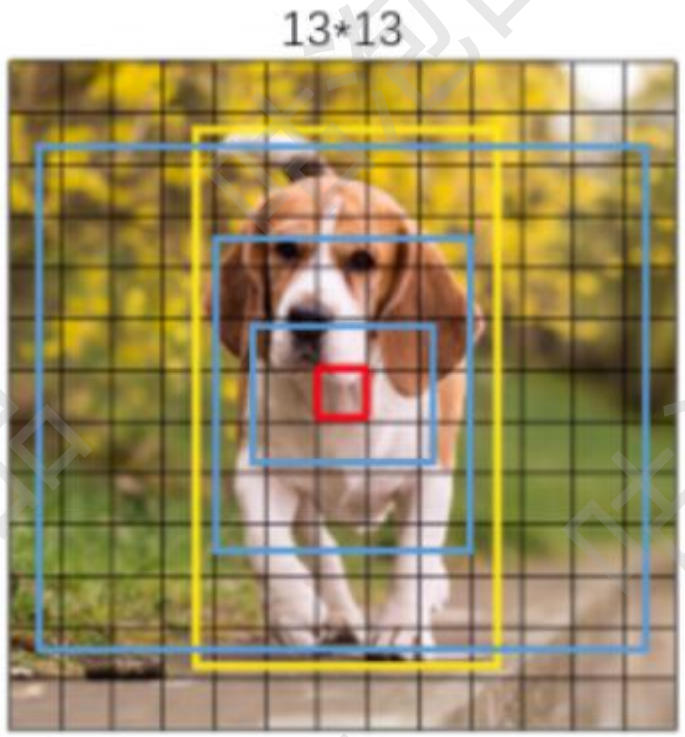

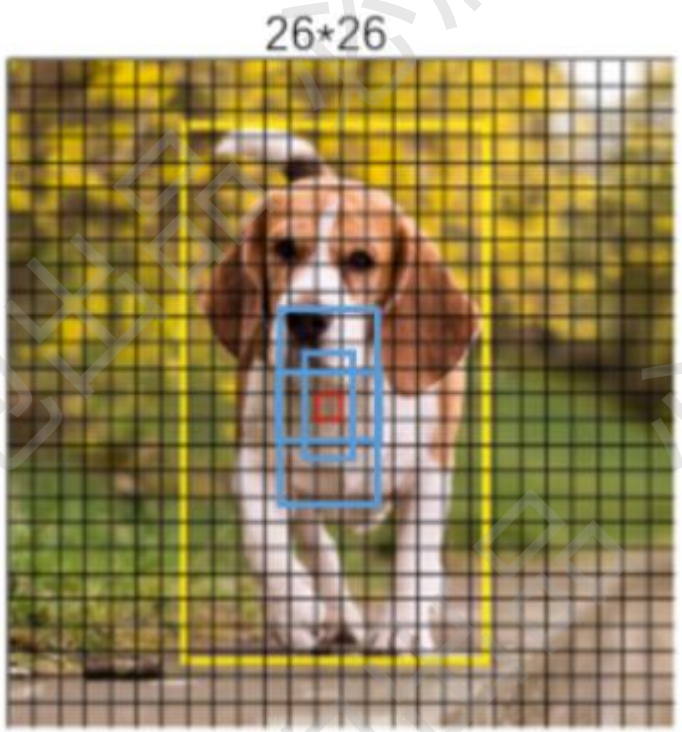

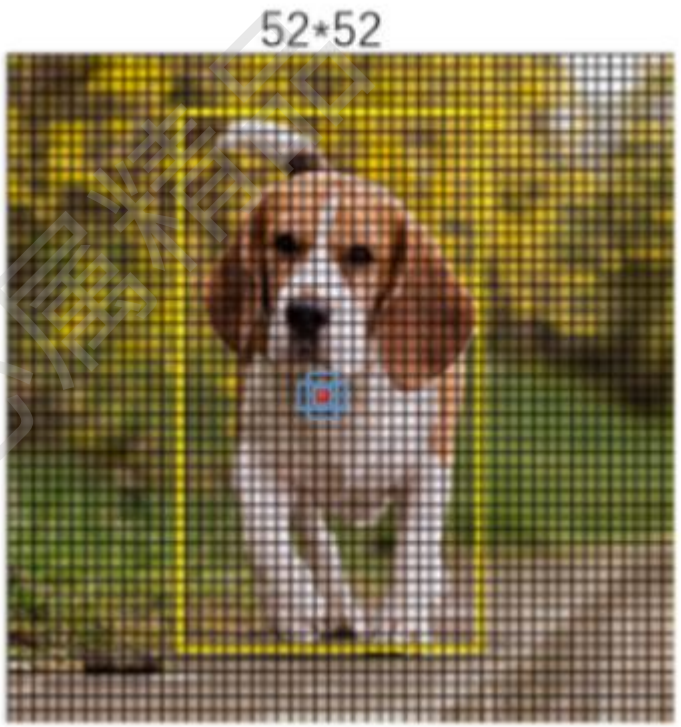

YOLO系列

- softmax层替代

  - 物体检测任务中可能一个物体有多个标签

  - logistic激活函数来完成，这样就能预测每一个类别是/不是